

张泰宇

xiannian0311@gmail.com · +8618843980900 · ssstirm.github.io



个人简介

KU Leuven 计算机科学系博士在读。覆盖语言模型完整生命周期：从零预训练（40GB 中文清洗语料、GPT-2 量级，落地讯飞输入法）、大模型蒸馏（LingBot 视频扩散，单次生成 50 分钟 → < 4 分钟）、自回归序列建模（文本到动作），以及 LLM Agent 系统（IVA 2024 一作；GitHub 1.3k+ stars）。

工作经历

兼职研究员 — 魔芯科技 2026.03 – 2026.05

- 在华为昇腾服务器上完成 14B teacher 到 14B student 的 self-forcing 蒸馏；在此基础上引入相机轨迹控制条件化。
- 在 1000 帧长视频预训练模型上对学生模型完成 4 步少步蒸馏。

NLP 研究员 — 科大讯飞 2021 – 2022

- 参与多个国家级科研项目；主要负责讯飞数字人多语种语义理解部分——数据筛选、模型训练、测试评估。
- 成果落地 2022 北京冬奥等多个国家重点活动。
- 输入法长句补全 GPT 从零预训练（详见代表项目）。

代表项目

讯飞输入法长句补全 — GPT 从零预训练 2021 – 2022

- 数据工程：把 400GB 输入法原始语料清洗为 40GB 预训练集——去重、语言与质量过滤、话题分布均衡、格式规整。
- 在清洗后的中文语料上从零预训练 GPT 风格语言模型。
- 上线讯飞输入法，作为长文本补全与诗词创作功能的底座。

LingBot 蒸馏 — 14B 视频扩散 → 4 步学生（昇腾） 2026.03 – 2026.05

- 在华为昇腾（CANN）上复现 LingBot 蒸馏；教师模型支持相机轨迹控制 + 1000 帧长视频。40–50 步教师 → 4 步学生；单次生成 > 50 分钟 → < 4 分钟。
- 解决 self-forcing 训练显存瓶颈：两次前向 + activation 重算（梯度累计风格）；提出新的 ODE 初始化方法，用训练数据直接从 teacher 初始化 student，省去显式 ODE pair 生成、稳定蒸馏。

Focus Agent — 第一作者，IVA 2024 2023 – 2024

- 由 LLM 驱动的虚拟焦点小组：每位参与者带独立人设、推理风格与对话记忆；主持人按访谈目标引导。
- 论文发表于第 24 届 ACM 智能虚拟代理国际会议。

Claw-AI-Lab — 联合开发者 2025 – 至今

- 自主多智能体研究平台：一句 prompt 产出论文、代码、配图与实验日志一体化交付。GitHub 1.3k+ stars ([Claw-AI-Lab/Claw-AI-Lab](#))。
- 参与多智能体调度器、本地执行 harness、实时监控 Dashboard 等模块的开发。

3D 角色动画生成 — 自回归 token 模型 + 蒸馏 2023 – 2025

- 跟踪文本到动作生成两条分支：基于离散 VQ-VAE / VQGAN token 的自回归（T2M-GPT、Momask、MotionGPT）与扩散（MDM 及后续）。
- 自回归侧用 VQGAN 替代 VQ-VAE 作为动作 tokenizer（提升序列重建精度）；扩散侧做少步蒸馏（保持 FID 几乎不变）。

教育经历

博士，计算机科学 — 鲁汶大学（KU Leuven） 2022 – 至今

研究方向：三维环境中的智能虚拟代理。导师：Adalberto L. Simeone 教授。

硕士，电子工程 — 清华大学 2018 – 2021

导师：马晓红教授。

学士，电子工程与信息科学 — 中国科学技术大学 2014 – 2018

导师：唐建教授。

代表发表

Focus Agent: LLM-Powered Virtual Focus Group.

张泰宇 等. 第 24 届 ACM 智能虚拟代理国际会议（IVA）论文集, 2024 年.

技能

编程语言 Python · C++ · Swift · TypeScript · C#

ML / 系统 PyTorch · 预训练 · 模型蒸馏 · Tokenization (VQ-VAE / VQGAN) · 分布式训练 · 昇腾 / CANN

建模 Transformer / GPT · 扩散模型 · 自回归序列建模 · 多智能体编排

语言 英语（流利）· 中文（母语）